




INTRODUCCIÓN AL MACHINE LEARNING APLICADO AL AUDIO

Teoría e Implementación



Diciembre 2023, Universidad de Chile
Profesor: P.h.D Rodolfo Lobo C.





INTRODUCCIÓN AL MACHINE LEARNING APLICADO AL AUDIO

Teoría e Implementación



Diciembre 2023, Universidad de Chile
Profesor: P.h.D Rodolfo Lobo C.

MODELOS AVANZADOS



Redes Recurrentes, Redes Convolucionales, GANs



Objetivos de la Clase

Al finalizar la clase tú aprenderás:



Objetivos de Aprendizaje:

- Conocer la arquitectura de una red convolucional estándar.
- Entender cómo se aplica la operación de convolución.
- Entender cómo se aplica la operación de convolución.

¿Cómo lo Lograremos?:



- A través de la revisión de conceptos de la literatura.
- Ejemplos en Notebooks de Google Colab.
- Algunos ejemplos de cálculos a mano!.

¿Qué son las redes convolucionales?




Evolución histórica

Cell Study
Hubel and
Torsten




Self-supervised
vision model:
neocognitron




An early (Le-Net5) Convolutional Neural Network design, LeNet-5, used for recognition of digits

Lenet-5: gradient
descent + conv
network based on
neocognitron
ideas.





¿Qué es una red convolucional?


Es una red neuronal que utiliza una operación llamada "convolución" a los valores de entrada. Se basa en el funcionamiento de células neuronales del córtex visual (Hubel, Wiesel 1950 - 1960). Comúnmente se utilizan en problemas asociados a imágenes.




¿Qué es una red convolucional?




¿Qué es una red convolucional?



- 3D
- Imágenes
- Kernels/Filtros



¿Qué aprende este tipo de redes?



Parámetros de una Red Convolutacional CNN

La estructura y funcionalidad de una red convolutacional puede dividirse en 4 partes fundamentales, cuando es utilizada particularmente con información visual:

- La capa de entrada que recibe los píxeles de la imagen.
- La capa convolutacional que determina qué salidas están conectadas a regiones locales de la entrada (reconocer relaciones y estructuras dentro de las imágenes), a través de productos escalares entre los filtros y las sucesivas capas de entrada. Aplicar una función de activación no lineal, generalmente ReLU, componente a componente.
- Aplicar Pooling, que se puede definir de manera simple como una reducción de dimensión del espacio vectorial en el cual se encuentra una salida de una capa convolutacional, reduciendo el número de parámetros.
- Y finalmente, una red totalmente conectada, que permite calcular scores o clases desde las funciones de activación. En el caso de clasificar, se utilizan funciones como la softmax y funciones de pérdida como la entropía.

Parámetros de una Red Convolucional CNN

Ejemplo de como se ve la arquitectura de una red convolucional utilizando tensorflow-keras [\[LINK EJEMPLO\]](#)

Model: "model"

Layer (type)	Output Shape	Param #
input_4 (InputLayer)	[(None, 32, 32, 3)]	0
conv2d_4 (Conv2D)	(None, 30, 30, 32)	896
max_pooling2d_2 (MaxPooling 2D)	(None, 15, 15, 32)	0
conv2d_5 (Conv2D)	(None, 13, 13, 64)	18496
max_pooling2d_3 (MaxPooling 2D)	(None, 6, 6, 64)	0
conv2d_6 (Conv2D)	(None, 4, 4, 128)	73856
flatten_1 (Flatten)	(None, 2048)	0
dense (Dense)	(None, 10)	20490

=====
Total params: 113,738

Trainable params: 113,738

Non-trainable params: 0

Parámetros de una Red Convolucional CNN

Ejemplo de como se ve la arquitectura de una red convolucional utilizando tensorflow-keras [\[LINK EJEMPLO\]](#)

Model: "model"

Layer (type)	Output Shape	Param #
input_4 (InputLayer)	[(None, 32, 32, 3)]	0
conv2d_4 (Conv2D)	(None, 30, 30, 32)	896
max_pooling2d_2 (MaxPooling 2D)	(None, 15, 15, 32)	0
conv2d_5 (Conv2D)	(None, 13, 13, 64)	18496
max_pooling2d_3 (MaxPooling 2D)	(None, 6, 6, 64)	0
conv2d_6 (Conv2D)	(None, 4, 4, 128)	73856
flatten_1 (Flatten)	(None, 2048)	0
dense (Dense)	(None, 10)	20490

=====
Total params: 113,738
Trainable params: 113,738
Non-trainable params: 0

→ (image_height, image_width, image_channels)

Parámetros de una Red Convolucional CNN

Ejemplo de como se ve la arquitectura de una red convolucional utilizando tensorflow-keras [\[LINK EJEMPLO\]](#)

Model: "model"

Layer (type)	Output Shape	Param #
input_4 (InputLayer)	[(None, 32, 32, 3)]	0
conv2d_4 (Conv2D)	(None, 30, 30, 32)	896
max_pooling2d_2 (MaxPooling 2D)	(None, 15, 15, 32)	0
conv2d_5 (Conv2D)	(None, 13, 13, 64)	18496
max_pooling2d_3 (MaxPooling 2D)	(None, 6, 6, 64)	0
conv2d_6 (Conv2D)	(None, 4, 4, 128)	73856
flatten_1 (Flatten)	(None, 2048)	0
dense (Dense)	(None, 10)	20490

=====
Total params: 113,738
Trainable params: 113,738
Non-trainable params: 0

→ (image_height, image_width, image_channels)

Tensor de rango 3

Parámetros de una Red Convolucional CNN

Ejemplo de como se ve la arquitectura de una red convolucional utilizando tensorflow-keras [\[LINK EJEMPLO\]](#)

Model: "model"

Layer (type)	Output Shape	Param #
input_4 (InputLayer)	[(None, 32, 32, 3)]	0
conv2d_4 (Conv2D)	(None, 30, 30, 32)	896
max_pooling2d_2 (MaxPooling 2D)	(None, 15, 15, 32)	0
conv2d_5 (Conv2D)	(None, 13, 13, 64)	18496
max_pooling2d_3 (MaxPooling 2D)	(None, 6, 6, 64)	0
conv2d_6 (Conv2D)	(None, 4, 4, 128)	73856
flatten_1 (Flatten)	(None, 2048)	0
dense (Dense)	(None, 10)	20490

=====
Total params: 113,738
Trainable params: 113,738
Non-trainable params: 0

→ (image_height, image_width, image_channels)

Tensor de rango 3

→ El número de canales del filtro debe coincidir con el número de canales de la imagen. Por ejemplo, en el caso de la imagen de CIFAR, es de 32x32x3 y eventualmente podríamos usar un filtro 5x5x3, donde el último 3 representa el número de canales. En el caso de imágenes representa los canales RGB (red-green-blue)

Capa de Pooling

- Se utiliza generalmente después de una capa convolucional
- Se utiliza para disminuir el ancho y alto en las dimensiones de las capas internas.
- Reduce el número de parámetros, evita el overfit y disminuye el tiempo de cómputo.
- Una de las formas más utilizadas es el max pooling, ejemplo:

Single depth slice

1	1	2	4
5	6	7	8
3	2	1	0
1	2	3	4

max pool with 2x2 filters
and stride 2



6	8
3	4



W o H (ancho o alto pueden ser sustituidos en esta expresión, F es el tamaño del filtro y S el tamaño del paso)

$$\text{Outputdim} = \frac{W - F}{S} + 1$$

Capa de Pooling

- Se utiliza generalmente después de una capa convolucional
- Se utiliza para disminuir el ancho y alto en las dimensiones de las capas internas.
- Reduce el número de parámetros, evita el overfit y disminuye el tiempo de cómputo.
- Una de las formas más utilizadas es el max pooling, ejemplo:

Single depth slice


1	1	2	4
5	6	7	8
3	2	1	0
1	2	3	4

max pool with 2x2 filters
and stride 2



6	8
3	4


Ejemplo de Convolución




Capa Totalmente Conectada (Fully Connected)

- También es llamada de capa densa.
- Recibe la salida de todas las neuronas de una capa previa.
- Las capas de convolución y pooling se utilizan para extraer información relevante de las imágenes.
- Esta capa final, permite clasificar información de alto nivel de abstracción obtenida por las capas convolucionales.

Bordes



Texturas



Patrones



Partes



Objetos





Aspectos Importantes

- Es posible utilizar más de 1 filtro en cada capa convolucional. Por ejemplo, podemos usar 7 filtros 5x5x3 lo que daría por salida un objeto de tamaño H x W x 6. Donde H y W, o las nuevas dimensiones tras la convolución pueden ser calculadas a través de una fórmula.
- La fórmula es dada de forma general por:

$$\text{Outputdim} = \frac{N - F + 2P}{S} + 1$$



Ejemplo 1 de Convolución



1	2	0	2	1	2
0	1	2	1	3	0
1	2	1	1	0	0
2	1	4	0	0	1
2	1	0	2	1	1
2	3	1	0	1	0

0	1	2	2	0	1
1	2	0	0	2	4
4	3	2	1	2	0
0	2	2	1	0	3
2	1	3	0	0	1
2	1	0	2	1	0

Ejemplo 1 de Convolución




1	0	1
0	2	0
1	1	1

0	1	1
1	0	1
1	2	1


Ejemplo 1 de Convolución

step 1




Ejemplo 1 de Convolución


step 2



Ejemplo 1 de Convolución



Ejemplo 1 de Convolución



Ejemplo 1 de Convolución Padding

Step 1

0	0	0	0	0	0	0	0	0
0	0	1	2	2	0	1	0	0
0	1	2	0	0	2	4	0	0
0	4	3	2	1	2	0	0	0
0	0	2	2	1	0	3	0	0
0	2	1	3	0	0	1	0	0
0	2	1	0	2	1	0	0	0
0	0	0	0	0	0	0	0	0

Step 2

0	0	0	0	0	0	0	0	0
0	0	1	2	2	0	1	0	0
0	1	2	0	0	2	4	0	0
0	4	3	2	1	2	0	0	0
0	0	2	2	1	0	3	0	0
0	2	1	3	0	0	1	0	0
0	2	1	0	2	1	0	0	0
0	0	0	0	0	0	0	0	0

Step 3

0	0	0	0	0	0	0	0	0
0	0	1	2	2	0	1	0	0
0	1	2	0	0	2	4	0	0
0	4	3	2	1	2	0	0	0
0	0	2	2	1	0	3	0	0
0	2	1	3	0	0	1	0	0
0	2	1	0	2	1	0	0	0
0	0	0	0	0	0	0	0	0


↑
This column
and this row
are dropped

Ejemplo 1 de Convolución: representacion

0	1	2	2	0	1	0x
1	2	0	0	2	4	
4	3	2	1	2	0	1x
0	2	2	1	0	3	
2	1	3	0	0	1	2x
2	1	0	2	1	0	4x

Cantidad de veces que aparece
una posición del arreglo bajo el
cálculo de convolución


Ejemplo 1 de Convolución: representación



Teniendo en cuenta que estamos dando pasos de a 2, es posible representar la operación de convolución como producto de matrices!


Vemos que tenemos 2 filtros de 3x3

Ejemplo 1 de Convolución: representación



Teniendo en cuenta que estamos dando pasos de a 2, es posible representar la operación de convolución como producto de matrices!

Ejemplo 1 de Convolución: representación



Los colores representan la frecuencia con que aparecen los pixeles en el recorrido de los kernels.

La matriz modificada del centro se transformó para hacer coincidir las dimensiones con los kernels.

Los valores recorridos por el kernel. Por fila, se colocan de forma vertical. En el primer canal Alcanzamos a recorrer en la primera fila los valores: 0 - 1 - 2 Y 2 - 2 - 0. Luego pasamos a la fila 3, con valores: 4 - 3 - 2 etc.

Ejemplo 1 de Convolución: representación

0	2	4	2
1	2	3	1
2	0	2	2
1	0	0	2
2	0	2	1
0	2	2	0
4	2	2	3
3	1	1	0
2	2	3	0



Primera fila de cada canal
recorrida por los filtros


Ejemplo 1 de Convolución: representación

0	2	4	2
1	2	3	1
2	0	2	2
1	0	0	2
2	0	2	1
0	2	2	0
4	2	2	3
3	1	1	0
2	2	3	0




Segunda fila de cada canal recorrida por los filtros

Ejemplo 1 de Convolución: múltiples instancias




3 instancias de kernels de tamaño 3x3 con dos canales

Ejemplo 1 de Convolución: múltiples instancias



3 instancias de kernels de tamaño 3x3 con dos canales

Ejemplo de Convolución



Filtro 2

$w1[:, :, 0]$

0	-1	1
1	-1	-1
-1	1	1

$w1[:, :, 1]$

1	0	0
1	1	0
1	-1	0

$w1[:, :, 2]$

1	-1	1
0	-1	0
-1	0	1

Bias $b1$ (1x1x1)

$b1[:, :, 0]$

0

Bias

Salida

$o[:, :, 0]$

4	-4	0
-3	-1	2
4	-1	1

$o[:, :, 1]$

0	3	4
4	1	-1
1	5	-4

Tamaño de paso: 2 (Stride)

Ejemplo Tensorflow-Keras + CIFAR 10

[NOTEBOOK LINK](#)




Referencias principales

- Introduction to Probability for Data Science, Stanley H. Chan, 2021, Michigan Publishing. ISBN 978-1-60785-747-1
- Python Crash Course: a hands -on project-based introduction to programming.
- Second Edition. ISBN-13: 978-1593279288
- Deep Learning, Ian Good Fellow, Yoshua Bengio and Aaron Courville. MIT Press, 2016. ISBN, 0262035618, 9780262035613
- Neural Networks and Learning Machines, Haykin Simon, 2008. Third Edition
- ISBN 10: 0131471392 ISBN 13: 9780131471399.
- <https://github.com/musikalkemist/AudioSignalProcessingForML>
- Approaching (ALMOST) Any Machine Learning Problem, Abhishek Thakur, 2019.
- Deep Learning with Python, François Chollet, 2021, Second Edition, Manning Shelter Island.
- Python DataScience Handbook, Essential Tools for Working with Data. Jake VanderPlas O'Reilly, 2016, First Edition.
- <https://www.coursera.org/specializations/machine-learning-introduction>
- <https://github.com/keunwoochoi/dl4mir>
- <https://christophm.github.io/interpretable-ml-book/cnn-features.html>
- <https://arxiv.org/pdf/1511.08458.pdf>

Referencias de esta presentación

- <https://christophm.github.io/interpretable-ml-book/cnn-features.html>
- <https://arxiv.org/pdf/1511.08458.pdf>

Gracias!



¿Preguntas?

rodolfo@ug.uchile.cl



CREDITS: This presentation template was created by
Slidesgo, including icons by Flaticon, and infographics
& images by Freepik

Please keep this slide as attribution